

ESERCIZIO 1

ANOMALIE RILEVATE

Per individuare le anomalie nel dataset, ho caricato i dati in un DataFrame e analizzato i valori unici di ciascun campo. A partire da questi, ho effettuato un'analisi manuale per identificare eventuali errori o valori anomali.

Di seguito sono riportate le anomalie riscontrate nei campi 'data', 'ora', 'totale' e 'partita IVA'.

Data

- Le annotazioni relative alle date presentano formati estremamente eterogenei. Alcuni esempi includono valori come "00/00/00", "Thu 00 Jun 0000", "00.0.00000" e "00-00-0000".
- Quando vengono utilizzate parole per indicare il mese o il giorno, queste appaiono talvolta in italiano e altre volte in lingue differenti, come evidenziato da esempi quali "Thu 00 Jun 0000" e "Maggio 00, 0000".
- In diversi casi, oltre alla data, i valori includono caratteri isolati, come la lettera "G", oppure caratteri speciali non pertinenti, come il simbolo di percentuale "%". Sono inoltre presenti porzioni di testo aggiuntivo irrilevante o ridondante rispetto al contenuto atteso, tra cui stringhe come "Date:" e "Stampato:".

Ora

- Le annotazioni relative agli orari presentano formati estremamente differenti. Alcuni esempi includono valori come "00:00", "00:00:00" e "00/00".
- In alcuni casi viene indicata anche la componente dei secondi, mentre in altri no.
- In alcuni casi compare l'indicazione "PM", mentre in altri è completamente assente, rendendo il formato dell'orario non uniforme.
- In diversi record, oltre all'orario, i valori includono caratteri isolati, come la lettera "h", oppure caratteri speciali non pertinenti, come la chiocciola "@", o ancora porzioni di testo aggiuntivo che risultano irrilevanti o ridondanti rispetto al contenuto previsto, come ad esempio stringhe del tipo "Ora:".
- Si rileva inoltre che, all'interno dei valori relativi all'orario, alcune annotazioni utilizzano parole in italiano, mentre altre utilizzano lingue diverse. Ad esempio, si osservano valori come "ORA00:00" (italiano) e "Hora:00:00" (spagnolo).

Totale

- Il campo "totale" include valori che non rappresentano correttamente importi monetari, come ad esempio "00/00/0000" o "0/00".
- Per quanto riguarda la valuta, si osserva una forte eterogeneità: in alcuni casi viene utilizzato il simbolo (ad esempio €, \$, £), in altri si adotta il codice ISO 4217 (come "EUR"), mentre in altri ancora la valuta risulta completamente assente.

- Inoltre, quando la valuta è presente, può comparire sia all'inizio che alla fine della cifra, come si può osservare in esempi quali "€0.00" oppure "00.00EUR".
- Anche il separatore tra parte intera e parte decimale non è uniforme: talvolta viene utilizzata la virgola (esempio "00,00"), altre volte il punto (esempio "00.00").
- Analogamente, per la separazione delle migliaia, in alcuni casi il separatore non viene utilizzato, mentre in altri si alternano l'uso del punto e della virgola, come si osserva in valori quali "0,000.00" e "0.000,00".
- Sono presenti anche casi in cui appaiono spazi all'interno del valore numerico, come in "0.00 00" o "0, 00".
- Infine, in diversi valori, oltre al punto e alla virgola, compaiono caratteri speciali non pertinenti, come il simbolo di percentuale "%", che risultano incoerenti con il contenuto atteso del campo. È stato inoltre rilevato un valore contenente il segno negativo "-", che, in assenza di informazioni più dettagliate sul dataset, presumo al momento essere un'anomalia da segnalare.

Partita IVA

- Le partite IVA presenti nel dataset sono registrate in formati molto eterogenei. In alcuni casi compaiono senza alcun prefisso, come "00000000000", mentre in altri sono precedute da codici paese, come in "SI000000000" o "IT000000000000".
- Alcuni valori contengono caratteri speciali come trattini, slash o spazi, ad esempio "00000000000.", "0000/00000", "00000000000->00" o "00000000/00".
- Sono inoltre presenti annotazioni che includono porzioni di testo non rilevanti, che non aggiungono informazioni utili e possono generare ambiguità, come "-TEL." o abbreviazioni parziali come "P,IVA".

PIANO DI VALIDAZIONE AUTOMATICA

Propongo di adottare una logica di validazione automatica che esegua un controllo sui valori di ciascun record del dataset e applichi strategie di validazione differenti in base al campo a cui ciascun valore appartiene.

Più precisamente, per ogni record del dataset, i valori verranno analizzati individualmente: ciascun valore sarà sottoposto ai controlli previsti secondo le regole definite qui sotto in base alla tipologia di campo a cui appartiene.

Se per un record vengono rilevati uno o più errori nei valori, il sistema dovrebbe registrarli e associarli al relativo record. Al termine dell'elaborazione, il sistema restituirà un elenco degli errori rilevati, organizzato per ciascun record.

Data

Per il campo "data", sarebbe innanzitutto necessario adottare e rinforzare l'utilizzo di uno standard uniforme, ad esempio il formato **DD/MM/YYYY**. Una volta concordato il formato prescelto, consiglio di applicare ai valori di questo campo i seguenti controlli:

- Verificare che ogni valore rispetti esattamente la struttura prevista, ossia due cifre per il giorno, due per il mese e quattro per l'anno, separati da slash ("/").
- Verificare che i valori non contengano lettere, simboli speciali non ammessi o parole aggiuntive come "Data:", "Stampato:" e simili.
- Assicurarsi che la combinazione giorno/mese/anno formi una data reale (ad esempio, che il 31/02/2025 venga rilevato come errore poiché febbraio non ha 31 giorni).
- Rilevare eventuali valori vuoti o nulli.

Per l'implementazione della logica di validazione proposta, suggerisco di seguire i seguenti passaggi:

1. Il primo step consiste nell'assicurarsi che il valore del campo "data" non sia vuoto o mancante.
2. Rimuovere temporaneamente tutti gli spazi vuoti presenti nel valore, inclusi quelli all'inizio, alla fine e all'interno della stringa.
3. Successivamente, si verifica che il valore rispetti il formato atteso. A tale scopo, è possibile utilizzare un'espressione regolare come la seguente:

```
^(0[1-9]|[12][0-9]|3[01])\.(0[1-9]|1[0-2])\.(19|20)\d\d$
```

Questa regex consente di controllare che la data sia formalmente corretta, nel formato **DD/MM/YYYY**, e che i numeri rientrino nei range ammessi per giorni, mesi e anni.

4. Infine, per accertarsi che la data esista realmente nel calendario, si può utilizzare il modulo `datetime` di Python. In particolare, il metodo `strptime()` permette di tentare la conversione del valore in un oggetto `datetime`. Se la data non è valida (ad esempio "31/02/2025"), il metodo solleva un'eccezione (`ValueError`), che può essere intercettata per segnalare il valore come errato.

Nel processo di validazione del campo "data", se uno qualsiasi dei passaggi sopra descritti fallisce — ovvero, se il valore risulta mancante, non conforme al formato atteso oppure non corrispondente a una data reale del calendario — il sistema dovrà segnalare l'errore, classificando il valore nel campo "data" come non valido ai fini della qualità complessiva del dataset.

Ora

Per il campo "ora", è fondamentale adottare uno standard uniforme per garantire coerenza nei valori. Si consiglia l'utilizzo del formato a 24 ore, ad esempio **HH:MM** o **HH:MM:SS**, evitando varianti ambigue come l'indicazione "AM/PM", che può introdurre incertezza e complessità nella normalizzazione.

Una volta definito il formato standard, suggerisco i seguenti passaggi di validazione:

- Verificare che i valori non siano nulli o vuoti, ovvero che contengano effettivamente un'informazione utilizzabile.
- Assicurarsi che i valori non includano lettere, simboli speciali o parole aggiuntive non pertinenti, come "Ora:", "HORA:", "@", o abbreviazioni come "h".
- Verificare che ciascun valore rispetti esattamente il formato previsto, ovvero due cifre per l'ora, due per i minuti e, opzionalmente, due cifre per i secondi, separati dal carattere ':'. Sono quindi ammessi valori come 13:45 o 08:15:30, mentre devono essere esclusi formati come 00.00, 00-00 o 00,00.

Per l'implementazione della logica di validazione proposta, suggerisco di seguire i seguenti passaggi:

1. Il primo step consiste nell'assicurarsi che il valore del campo "ora" non sia vuoto o mancante.
2. Rimuovere temporaneamente dal valore ogni spazio vuoto, sia all'inizio, sia alla fine, sia all'interno della stringa.
3. Successivamente, si verifica che il valore rispetti il formato atteso. A tale scopo, è possibile utilizzare un'espressione regolare come la seguente:

```
^([01]\d|2[0-3]):[0-5]\d(:[0-5]\d)?$
```

Questa regex consente di controllare che l'orario sia formalmente corretto, secondo il formato a 24 ore, accettando sia valori con solo ore e minuti (es. 14:30), sia con anche i secondi (es. 14:30:45).

Nel processo di validazione del campo "ora", se uno qualsiasi dei controlli indicati fallisce — ad esempio, se il valore è mancante, contiene testo non pertinente o non rispetta il formato previsto — il sistema dovrà segnalare l'errore, classificando il valore nel campo "ora" come non valido ai fini della qualità complessiva del dataset.

Totale

Per il campo "totale", si raccomanda di utilizzare il **codice ISO 4217** per indicare la valuta, al fine di evitare ambiguità. Simboli come \$, infatti, possono riferirsi a più valute (dollari statunitensi, canadesi, australiani, ecc.), mentre l'uso di un codice standardizzato come USD o EUR consente una corretta interpretazione automatica.

Un altro aspetto critico riguarda l'uso dei separatori numerici, sia per le migliaia che per la parte decimale.

Il separatore delle migliaia può essere:

- assente,
- uno spazio (ad esempio 1 528 225),
- oppure un punto (.) o la virgola (,), ma questi simboli possono generare ambiguità, poiché in molti contesti internazionali sono usati anche come separatori decimali.

Per garantire chiarezza e compatibilità internazionale, consiglio di evitare l'uso di separatori per le migliaia oppure, in alternativa, di ammettere esclusivamente lo spazio come separatore, in modo opzionale.

Riguardo al separatore della parte decimale, in Italia è comunemente utilizzata la virgola, come in 1530,00 €, mentre nei paesi anglosassoni viene invece adottato il punto, ad esempio 1530.00 USD.

Per assicurare uniformità e semplificare la validazione automatica, si propone di adottare il seguente standard:

- Indicare il valore numerico senza separatori per le migliaia, oppure, se previsto, ammettere esclusivamente lo spazio come separatore.
- Utilizzare punto oppure virgola come separatore decimale.
- La parte decimale può avere una cifra, o due.
- Specificare il codice ISO 4217 della valuta, subito dopo la cifra, con la possibilità di inserire uno spazio o più tra la cifra e il codice, al fine di migliorarne la leggibilità.

Una volta concordato lo standard di rappresentazione del totale, si suggerisce di applicare i seguenti controlli per ciascun valore del campo:

- Verificare che il campo contenga effettivamente un dato, ovvero che non sia vuoto o nullo.
- Accertarsi che nella parte numerica compaiano esclusivamente cifre, spazi, e un singolo punto oppure una virgola come separatore decimale, escludendo ogni altro simbolo o carattere speciale.
- Verificare che, dopo la cifra, sia presente un codice ISO 4217 corrispondente alla valuta.
- Controllare che il codice ISO 4217 sia composto solo da lettere (senza simboli come €, \$, %, ecc.) e che corrisponda effettivamente a uno dei codici ufficiali riconosciuti dallo standard ISO. Non è necessario che sia scritto in maiuscolo, purché semanticamente corretto.
- Verificare che il codice ISO 4217 esista realmente.

Per l'implementazione della logica di validazione proposta, suggerisco di seguire i seguenti passaggi:

1. Il primo step consiste nell'assicurarsi che il valore del campo "totale" non sia vuoto o mancante.
2. Rimuovere temporaneamente dal valore ogni spazio vuoto, sia all'inizio, sia alla fine, sia all'interno della stringa.
3. Successivamente, si verifica che il valore rispetti il formato atteso. A tale scopo, è possibile utilizzare un'espressione regolare come la seguente:

```
^\d+(?:[.,]\d{1,2})?[A-Za-z]{3}$
```

Questa regex consente di verificare che il valore sia formalmente corretto con virgola oppure punto come separatore decimale. La parte decimale, se presente, può contenere fino a due cifre. Il codice valuta, conforme allo standard ISO 4217, deve essere composto da tre lettere e posizionato immediatamente dopo la cifra.

4. Infine, è necessario verificare che il codice valuta ISO 4217 esista realmente, confrontandolo con un elenco aggiornato di codici ufficiali. Questo controllo può essere effettuato integrando nel sistema una lista predefinita di codici ISO validi, oppure, in alternativa, ricorrendo a una soluzione automatizzata che acquisisca l'elenco più recente tramite web scraping o API da fonti affidabili.

Nel processo di validazione del campo "totale", se uno qualsiasi dei controlli descritti fallisce — ad esempio, se il valore è mancante, non rispetta il formato previsto oppure il codice valuta non è conforme allo standard ISO 4217 — il sistema deve segnalare l'errore e classificare il valore nel campo "totale" come non valido ai fini della qualità complessiva del dataset.

Partita IVA

Per il campo "partita IVA", è necessario adottare uno standard uniforme e obbligatorio, che preveda la presenza di un prefisso paese conforme allo **standard ISO 3166-1 alpha-2** (ad esempio IT, FR, SI, DE), seguito da una sequenza di sole cifre numeriche.

Una volta stabilito il formato da adottare, si consiglia di applicare ai valori di questo campo i seguenti controlli:

- Rilevare eventuali valori nulli o vuoti.
- Verificare che il valore inizi con due lettere alfabetiche, che rappresentano il prefisso ISO del paese.
- Assicursi che le lettere siano seguite da una sequenza di cifre, senza caratteri speciali come trattini (-), slash (/) o punti (.). Tuttavia, eventuali spazi interni alla parte numerica o tra il prefisso e la cifra possono essere tollerati.
- Escludere la presenza di stringhe non informative, come "P.IVA", "TEL.", "C.F./P.I.", che non fanno parte del codice formale e generano ambiguità.
- Verificare che il prefisso ISO sia valido, confrontandolo con un elenco aggiornato dei codici paese definiti dallo standard ISO 3166-1.
- Verificare che la partita IVA, una volta normalizzata (rimozione spazi), rispetti il formato finale atteso: due lettere seguite da 8 a 12 cifre.
- Controllare che la struttura della partita IVA sia conforme alle norme europee.

Per l'implementazione della logica di validazione proposta, suggerisco di seguire i seguenti passaggi:

1. Verificare che il valore non sia nullo o vuoto.
2. Rimuovere temporaneamente tutti gli spazi presenti nel valore, così da normalizzare il formato e semplificare le fasi successive della validazione.
3. Verificare che il valore rispetti il formato atteso. A tale scopo, è possibile utilizzare un'espressione regolare come la seguente:

`^[A-Za-z]{2}\d{8,12}$`

Questa regex garantisce che il valore sia composto da un prefisso di due lettere (codice paese ISO) seguito da 8 a 12 cifre, senza caratteri speciali o spazi.

4. Verificare che il prefisso ISO sia valido, confrontandolo con una lista aggiornata dei paesi riconosciuti dallo standard ISO 3166-1 alpha-2. Questo controllo può essere implementato integrando una lista statica o dinamica tramite web scraping o l'utilizzo di API ufficiali.
5. Verificare che la partita IVA sia conforme alle specifiche del paese indicato, secondo le norme europee (struttura, lunghezza, regole di controllo, eventuale checksum). Anche in questo caso è possibile automatizzare il controllo utilizzando fonti ufficiali accessibili via API o web scraping, come quelle offerte da **VIES** (sistema di validazione delle partite IVA europee gestito dalla Commissione Europea).

Nel processo di validazione del campo "partita IVA", se uno qualsiasi dei controlli indicati fallisce — ad esempio, se il valore è mancante, non rispetta la struttura prevista, contiene caratteri non ammessi, presenta un prefisso non conforme ai codici ISO riconosciuti, oppure se la partita IVA non risulta coerente con il formato previsto dalle normative europee — il sistema deve segnalare l'anomalia e classificare il valore nel campo "partita IVA" come non valido ai fini della qualità complessiva del dataset.

Esempio di dataset ideale

In conclusione, il formato corretto del dataset dovrebbe attenersi alla struttura riportata nel seguente esempio.

filename	data	ora	totale	partita iva
1.png	20/02/2025	20:04	100,00 EUR	IT90927309002
2.png	15/01/2024	09:30	125,50 EUR	FR25712049618
3.png	01/03/2025	13:15	89.99 EUR	DE123456789
4.png	31/12/2023	23:59	1 250,00 EUR	ESX1234567X
5.png	10/07/2024	07:45	340 EUR	NL123456789B01

Pseudocodice

Di sotto uno pseudocodice del sistema di validazione.

```
dataset = load_dataset()

list_of_all_errors_record_by_record = []

for each record in dataset:
    record_messages = {}                // Dizionario degli errori per questo record
    messages_data = []                 // Errori relativi al campo "data"
    messages_ora = []                  // Errori relativi al campo "ora"
    messages_partita_iva = []           // Errori relativi al campo "partita_iva"
    messages_totale = []                // Errori relativi al campo "totale"

    data = record["data"]
    ora = record["ora"]
    totale = record["totale"]
    partita_iva = record["partita_iva"]

    // --- Validazione campo DATA ---
    if data is empty:
        add "empty value" to messages_data

    remove all whitespace from data

    if data does not match regex ^(0[1-9]|[12][0-9]|3[01])/(0[1-9]|1[0-2])/(19|
20)\d\d$:
        add "invalid format" to messages_data

    if data is not a real calendar date:
        add "date does not exist" to messages_data

    if messages_data is not empty:
        record_messages["data"] = messages_data

    // --- Validazione campo ORA ---
    if ora is empty:
        add "empty value" to messages_ora

    remove all whitespace from ora

    if ora does not match regex ^([01]\d|2[0-3]):[0-5]\d(:[0-5]\d)?$:
        add "invalid format" to messages_ora

    if messages_ora is not empty:
        record_messages["ora"] = messages_ora

    // --- Validazione campo TOTALE ---
    if totale is empty:
        add "empty value" to messages_totale

    remove all whitespace from totale

    if totale does not match regex ^\d+(?:[.,]\d{1,2})?[A-Za-z]{3}$:
        add "invalid format" to messages_totale

    valuta = last 3 characters of totale
```



```

if valuta not in list_of_valid_ISO_4217_codes:
    add "invalid currency code" to messages_totale

if messages_totale is not empty:
    record_messages["totale"] = messages_totale

// --- Validazione campo PARTITA IVA ---
if partita_iva is empty:
    add "empty value" to messages_partita_iva

remove all whitespace from partita_iva

if partita_iva does not match regex ^[A-Za-z]{2}\d{8,12}$:
    add "invalid format" to messages_partita_iva

country_code = first two letters of partita_iva

if country_code not in list_of_valid_country_codes:
    add "invalid country code" to messages_partita_iva

if structure of partita_iva is not valid according to country rules:
    add "invalid structure for country" to messages_partita_iva

if messages_partita_iva is not empty:
    record_messages["partita_iva"] = messages_partita_iva

// --- Se ci sono errori, aggiungi il dizionario ai risultati finali ---
if record_messages is not empty:
    add { record: record_messages } to list_of_all_errors_record_by_record

return list_of_all_errors_record_by_record

```

Riferimenti

- **ISO 4217 – Codici delle valute:** Standard internazionale che definisce i codici a tre lettere per le valute (es. EUR per euro, USD per dollaro statunitense). Consultabile al link: https://it.wikipedia.org/wiki/ISO_4217
- **ISO 3166-1 alpha-2 – Codici dei Paesi:** Standard internazionale che assegna a ogni Stato un codice a due lettere (es. IT per Italia, FR per Francia). Maggiori informazioni su: https://it.wikipedia.org/wiki/ISO_3166-1_alpha-2
- **VIES – Sistema di verifica delle Partite IVA europee:** Portale ufficiale dell'Unione Europea per il controllo della validità delle Partite IVA registrate ai fini IVA comunitaria. Disponibile su: https://europa.eu/youreurope/business/taxation/vat/check-vat-number-vies/index_it.htm
- **Formato delle Partite IVA europee:** Riferimento utile per comprendere la struttura delle Partite IVA nei diversi Paesi membri dell'UE. Fonte: <https://marosavat.com/it/formato-partite-iva-europee/>
- **Indicazioni sulla corretta scrittura dei prezzi in euro:** Linee guida utilizzate per rappresentare correttamente i prezzi. Le indicazioni sono disponibili all'indirizzo: <https://www.yleniavernucci.com/wp-content/uploads/2021/04/come-si-scrivono-i-prezzi.pdf>

STRUTTURA E CONTENUTI CHIAVE DI UN REPORT DI VALIDAZIONE RICORRENTE

Ritengo che un report periodico di validazione dei dati debba includere le seguenti sezioni principali.

Introduzione

In questa sezione si fornisce una breve descrizione del dataset analizzato, indicando la data in cui è stato effettuato il controllo e il nome o la versione del dataset.

Ad esempio, si può specificare che il report fa riferimento alla validazione del dataset *"Scontrini Aprile 2025"*, analizzato in data *28 aprile 2025*.

Risultati della validazione

Segue poi la sezione dedicata ai risultati della validazione.

In questo punto, vengono indicati il numero totale di record analizzati, il numero di record con errori e la relativa percentuale. Suddivideremo gli errori per categoria, specificando quanti record hanno presentato problemi per ciascun campo. Una tabella di sintesi può aiutare a rendere questi dati facilmente leggibili.

Di seguito è riportato un esempio di tabella che può essere inclusa nel report per sintetizzare i risultati della validazione:

Tipo Errore	Record con Errore	Percentuale (%)
Data non valida	42	15.2%
Ora non valida	28	2.1%
Totale non valido	81	8.5%
Partita IVA non valida	21	12.0%

Dettaglio degli errori

Nel report dovrebbe esserci anche una parte dedicata al dettaglio degli errori, in cui si descrivono i principali problemi riscontrati durante la validazione. Si forniscono esempi concreti dei valori errati più frequenti, evidenziando i formati anomali, incoerenti o non standard.

Questa parte è utile per comprendere la natura degli errori e facilitare interventi correttivi mirati.

Confronto storico

Un aspetto utile, soprattutto in report ricorrenti, è includere un confronto con le validazioni precedenti. Qui si può confrontare il livello di qualità dei dati rispetto a controlli precedenti, indicando se ci sono stati miglioramenti o peggioramenti e se sono cambiati i tipi di errori più frequenti. Ad esempio, si potrebbe osservare che la percentuale di errori sull'ora è diminuita rispetto al mese precedente.

Azioni consigliate

È poi fondamentale proporre alcune azioni correttive in base ai risultati ottenuti. Queste possono includere suggerimenti operativi, come modificare i criteri di estrazione dei dati, migliorare i processi di inserimento o aggiornare le regole di validazione automatica. In altri casi, può essere utile valutare la sostituzione o il miglioramento della fonte dati.

Conclusione

Infine, il report dovrebbe concludersi con una valutazione complessiva della qualità del dataset. In base alla natura, alla frequenza e alla gravità degli errori rilevati, si potrà raccomandare una delle seguenti azioni:

- Procedere con l'utilizzo del dataset senza riserve.
- Procedere con alcune riserve e interventi correttivi successivi.
- Bloccare l'utilizzo del dataset fino a quando non verranno apportate le opportune correzioni.